

Mecanismo do Viés

A seleção restrita de dados prejudica a lógica do algoritmo porque o modelo aprende apenas com os exemplos que recebe no treinamento. No experimento, o sistema aprende a classificar tênis como “bonito” ou “feio” a partir de um conjunto pequeno de imagens. Como esses exemplos representam apenas alguns estilos específicos, o algoritmo passa a associar certas cores, formatos ou marcas a uma categoria. Assim, o modelo cria uma regra simplificada e acaba classificando novos tênis com base em padrões limitados. Isso gera uma visão distorcida da realidade, porque existem muitos estilos diferentes que não aparecem nos dados usados para treinar a inteligência artificial.

Consequência Social

Esse tipo de classificação pode gerar impacto quando sistemas automáticos influenciam opiniões ou recomendações. Uma pessoa que gosta de um estilo diferente pode sentir frustração ou desconforto ao ver um objeto parecido com algo que usa sendo classificado como “feio”. Em contextos profissionais, algoritmos assim podem influenciar decisões de recomendação ou destaque de produtos. Como consequência, certos estilos podem receber menos visibilidade simplesmente porque não estavam bem representados nos dados de treinamento.

Ação Mitigadora

Uma forma de reduzir esse problema é usar uma abordagem de **human-in-the-loop**, onde pessoas participam da revisão dos dados e dos resultados do modelo. Antes da implementação, revisores analisam o conjunto de imagens para garantir maior variedade de estilos, cores e tipos de tênis. Durante os testes, humanos observam erros de classificação e adicionam novos exemplos ao treinamento. Esse processo ajuda a melhorar o modelo e diminuir o risco de classificações injustas ou limitadas.